


独立深層学習行列分析に基づく 多チャネル音源分離

☆角野隼斗, 北村大地, 高宗典玄, 高道慎之介, 猿渡洋 (東大),
小野順貴 (首都大)

多チャネル音源分離


- 観測信号を利用し，混合前の音源信号を推定する技術




※ 以下の条件を仮定している

- 優決定条件 (観測マイク数 $\geq$ 音源数)
- 周波数領域上での瞬時混合 (ランク1空間モデル)

本研究の位置付け



- 生成モデル：多変量複素ガウス分布（Duongモデル [Duong+, 2009]）



■ 尤度関数

$$p(\mathbf{x}_{ij}; \Sigma_{ij}^{(x)}) = \frac{1}{\det(\pi \Sigma_{ij}^{(x)})} \exp \left(-\mathbf{x}_{ij}^H \Sigma_{ij}^{(x)-1} \mathbf{x}_{ij} \right)$$

↓
EMアルゴリズムに基づき空間モデル最適化

- EMアルゴリズムの反復に必要な計算量が多い
- 分離系を推定する手法は混合系を推定する手法に比べ高精度な分離が可能 [Kitamura+, 2016]

定式化

生成モデル：時間周波数分散変動型複素ガウス分布 [Févotte+, 2009]

$$p(\mathbf{Y}_n) = \prod_{i,j} p(y_{ij,n}) \leftarrow \begin{array}{l} \text{時間周波数の各スロットで} \\ \text{定義された複素ガウス分布} \end{array}$$
$$= \prod_{i,j} \frac{1}{\pi r_{ij,n}} \exp \left(-\frac{|y_{ij,n}|^2}{r_{ij,n}} \right)$$

n : 音源インデクス

複素要素の時間周波数行列
($I \times J$ 次元)

時間周波数に依存する分散
($= \mathbf{Y}_n$ のパワー)

観測信号の負対数尤度

$$-\log \mathcal{L} = \sum_{i,j,n} \left(\log r_{ij,n} + \frac{|w_{i,n}^H x_{ij}|^2}{r_{ij,n}} \right) - J \sum_i \log |\det \mathbf{W}_i|^2 + I J N \log \pi$$

$y_{ij,n} = w_{i,n}^H x_{ij}$

音源モデル

空間モデル

$-\log p(y_{ij,n})$

→ Minimize w.r.t. $\mathbf{W}_i, r_{ij,n}$

$$\mathbf{W}_i = (w_{i,1}, \dots, w_{i,N})^H$$

$$\mathcal{J}_{\text{ILRMA}} = \frac{1}{J} \sum_{i,j,n} \left[\log \sum_l t_{il,n} v_{lj,n} + \frac{|\mathbf{w}_{i,n}^H \mathbf{x}_{ij}|^2}{\sum_l t_{il,n} v_{lj,n}} \right] - \sum_i \log |\det \mathbf{W}_i|^2$$


音源モデル (低ランク性)

空間モデル (音源間が独立)

分散行列 $\mathbf{R}_n = \mathbf{T}_n \mathbf{V}_n$

分離行列 $\mathbf{W}_i$

交互に最適化



- 空間モデル (Wの推定) : 各音源が統計的に**独立**となる分離行列を推定
- 音源モデル (Rの推定) : 各音源の分散時間周波数行列の**低ランク**近似

$$\mathcal{J}_{\text{ILRMA}} = \frac{1}{J} \sum_{i,j,n} \left[\log \sum_l t_{il,n} v_{lj,n} + \frac{|\mathbf{w}_{i,n}^H \mathbf{x}_{ij}|^2}{\sum_l t_{il,n} v_{lj,n}} \right] - \sum_i \log |\det \mathbf{W}_i|^2$$

音源モデル (低ランク性)

空間モデル (音源間が独立)

音源によっては低ランク性が
成り立たない場合がある

音源・マイク位置, 部屋の形状,
残響時間などの膨大な物理要因に依存

事前に学習データを用いて音源モデル
の分散を推定する画像を作る

学習データの用意は非現実的
ブラインドに推定

DNNによる汎用的な音源モデルの構成

提案手法：独立深層学習行列分析


■ IDLMA (Independent Deeply Learned Matrix Analysis)

$$\mathcal{J} = \frac{1}{J} \sum_{i,j,n} \left(\log r_{ij,n} + \frac{|w_{i,n}^H x_{ij}|^2}{r_{ij,n}} \right) - \sum_i \log |\det \mathbf{W}_i|^2$$

音源モデル (DNN)

交互に最適化

空間モデル (音源間が独立)



■ 空間モデル：各音源が統計的に独立となる分離行列を推定


■ 音源モデル：分散行列 R_n を推定するDNNを各音源ごとに構成

提案手法：独立深層学習行列分析

■ IDLMA (Independent Deeply Learned Matrix Analysis)

$$\mathcal{J} = \frac{1}{J} \sum_{i,j,n} \left(\log r_{ij,n} + \frac{|\mathbf{w}_{i,n}^H \mathbf{x}_{ij}|^2}{r_{ij,n}} \right) - \sum_i \log |\det \mathbf{W}_i|^2$$


■ DNN音源モデル（音源ごとに構成）




■ IS divergenceに基づく最適化は $\mathcal{J}$ の赤枠部分の最小化（最尤推定）と等価

学習信号	DSD100（音楽データセット）Dev 50曲（Vo./Ba. & Vo./Dr.）
評価信号	DSD100 Test 25曲に対し，以下の配置のE2Aインパルス応答（ $RT_{60} = 300$ ms）を畳み込んだ信号
サンプリング周波数	8 kHz
STFTの設定	窓長 128, 256, 512, 1024 ms / シフト長: 窓長の半分
評価指標	Signal-to-Distortion Ratio (SDR) の改善量
比較手法	ILRMA / DNN+WF法 [Uhlich+, 2015] / Duong+DNN法 / 提案手法 (IDLMA)


配置1



配置2



■ DNNの入出力



■ モデル

DNNの構造

全結合NN 隠れ層4層（各層ユニット数1024）


活性化関数

ReLU（隠れ層及び出力層）

実験結果（STFTの窓長と性能の関係）

■ STFTの窓長と音源分離性能（平均SDR改善量） [dB] ※配置1と配置2の平均

窓長 [ms]	128	256	512	1024
Vo ./Ba. (ILRMA)	3.67	4.98	6.48	4.39
Vo ./Ba. (IDLMA)	11.03	12.30	13.04	11.11
Vo ./Dr. (ILRMA)	5.45	6.39	6.18	4.82
Vo ./Dr. (IDLMA)	6.89	10.09	5.77	6.02




瞬時混合仮定が不成立

統計バイアス増加
DNNのパラメータ数増加

- Vo./Ba.では窓長512 ms, Vo./Dr.では窓長256 msが最も性能が良い
- IDLMAの性能は窓長に関してトレードオフが存在

実験結果（従来手法との性能比較）


■ 空間モデル更新毎のSDR改善量（窓長512 ms, 配置1, Vo./Ba.）



■ 10回に1回 DNNで分散行列を更新

実験結果（従来手法との性能比較）

■ 空間モデル更新毎のSDR改善量（窓長512 ms, 配置1, Vo./Ba.）



■ 10回に1回 DNNで分散行列を更新

まとめ

- 従来の**ブラインド**音源分離手法（ILRMA）において、**音源モデル**を**DNN**によって推定する**教師あり**拡張手法（IDLMA）を提案した
- 提案手法（IDLMA）は、既存手法に対し優れた分離性能を示し、**分離系**の推定が**混合系**の推定よりも高速かつ高精度であることを示した

